

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Zadanie č.4
3D Gaussian Splatting

Počítačové videnie a spracovanie obrazu

Obsah

Zadanie	3
Riešenie	5
1.1 Spustenie postupu na referenčnom datasete	5
1.2 Snímanie vlastnej scény	9
1.3 Vyhodnotenie výsledkov	13
Záver	14

Zadanie

Cieľom zadania je oboznámiť sa s modernou metódou 3D rekonštrukcie scény pomocou 3D Gaussian Splatting (3DGS). Študent prejde celým pracovným postupom od fotografií až po interaktívny 3D viewer, najprv na referenčnom datasete a potom na vlastnoručne nasnímanej scéne.

Zadanie je dokopy za 25 b. a pozostáva z nasledujúcich úloh:

1. [5 b.] Spustenie postupu na referenčnom datasete.

Táto úloha slúži na pochopenie celého pracovného postupu a overenie funkčnosti prostredia ešte pred tým, ako budete pracovať na vlastnom datasete. Na referenčných dátach sa naučíte každý krok bez toho, aby ste riešili problémy so snímaním.

Stiahnite niektorý z verejne dostupných datasetov (napr. Tanks and Temples – truck, garden, alebo iný kompatibilný dataset). Z datasetu použite iba fotografie (adresár input/) – žiadne predpočítané dáta. Celý postup spustíte sami od začiatku podľa návodu NAVOD.md:

- a) ./run.sh – spustenie Docker kontajnera.
- b) colmap gui – spustenie COLMAP GUI a postupné vykonanie:
 - Feature extraction (model: SIMPLE_PINHOLE)
 - Feature matching (Exhaustive)
 - Reconstruction (Sparse)
 - Export modelu do distorted/sparse/0/
- c) python3 convert.py -s data/ – undistortion fotografií.
- d) python3 train.py -s data/ – trénovanie 3DGS modelu (30 000 iterácií, checkpointy po 7 000 a 30 000).
- e) SIBR_gaussianViewer_app -m output/ – vizualizácia výsledku.

Zdokumentujte postup screenshotmi z každého kroku (COLMAP GUI, priebeh trénovania, viewer). Uveďte dosiahnutú metriku PSNR po 7 000 a 30 000 iteráciách.

2. [10 b.] Snímanie vlastnej scény kamerou Ximea.

Vyberte a nasnímate vlastnú scénu priemyselnou kamerou Ximea (vysoké rozlíšenie). Fotografie downscalujte pred spustením COLMAP (odporúčame dlhšiu stranu na max. 600–1200 px) – kamera má príliš vysoké rozlíšenie na priame spracovanie a zároveň COLMAP aj 3DGS by bežali neúnosne dlho.

Spustite celý postup rovnako ako v úlohe 1. Uved'te dosiahnutú metriku PSNR a vizuálne porovnajte výsledok s referenčným datasetom.

3. [5 b.] Vyhodnotenie výsledkov.

Porovnajte výsledky oboch scén (referenčný dataset vs. vlastná scéna):

- tabuľka PSNR po 7 000 a 30 000 iteráciách,
- vizuálne porovnanie renderov z rovnakých uhlov pohľadu,
- komentár – čo ovplyvnilo kvalitu vlastnej scény (počet fotografií, osvetlenie, typ objektu, . . .).

4. [5 b.] Dokumentácia

Odovzdajte správu (PDF) obsahujúcu:

- popis každého kroku s príslušnými screenshotmi,
- popis procesu snímania vlastnej scény (čo, kde, ako),
- grafické porovnanie výsledkov,
- záver s odporúčaniami – čo by ste urobili inak pre lepšie výsledky.


Termín odovzdania: 12. cvičenie semestra

Riešenie

1.1 Spustenie postupu na referenčnom datasete

V prvej časti zadania bol použitý referenčný dataset obsahujúci sériu fotografií Lighthouse scény. Cieľom tejto časti bolo overiť funkčnosť pracovného prostredia a prejsť celý postup cez feature matching, rekonštrukciu až tréovanie bez problémov spôsobených vlastným snímaním. Postup sme skúšali na datasete Lighthouse a Truck.

Najskôr bol spustený Docker kontajner pomocou príkazu `./run.sh`. Následne bol v prostredí COLMAP vytvorený nový projekt. Ako vstupný priečinok bol nastavený adresár s fotografiami `input/` a ako databáza bol použitý súbor `database.db`. V kroku Feature Extraction boli z fotografií extrahované body pomocou modelu kamery `SIMPLE_PINHOLE`. Potom bolo vykonané párovanie snímok. Na základe nájdených zhôd bola spustená sparse rekonštrukcia, pri ktorej COLMAP vypočítal pozície kamier a vytvoril riedky 3D mrak bodov. Následne bola vykonaná undistortion, ktorá odstránila skreslenie a previedla snímky do pin-hole modelu.



Obr. 1: Riedka rekonštrukcia referenčnej scény v colmap gui.

```

root@d618-System-Product-Name: /opt/gaussian-splatting
ema_loss_for_log = 0.4 * loss.item() + 0.6 * ema_loss_for_log
KeyboardInterrupt
Training progress: 2%|          | 650/30000 [00:46<35:00, 13.92it/s, Loss=0.1294339, Depth Loss=0.0000000]

root@d618-System-Product-Name: /opt/gaussian-splatting# python3 train.py -s data --data_device cpu --resolution 2
Optimizing
Output folder: ./output/25fea626-b [05/05 11:14:06]
Tensorboard not available: not logging progress [05/05 11:14:06]
Reading camera 110/110 [05/05 11:14:06]
Loading Training Cameras [05/05 11:14:06]
Loading Test Cameras [05/05 11:14:09]
Number of points at initialisation : 67245 [05/05 11:14:09]
Training progress: 23%|          | 7000/30000 [05:35<26:22, 14.54it/s, Loss=0.0870104, Depth Loss=0.0000000]
[ITER 7000] Evaluating train: L1 0.03624053373932839 PSNR 23.66270637512207 [05/05 11:19:44]

[ITER 7000] Saving Gaussians [05/05 11:19:44]
Training progress: 100%|          | 30000/30000 [37:41<00:00, 13.26it/s, Loss=0.0391953, Depth Loss=0.0000000]

[ITER 30000] Evaluating train: L1 0.022002805955708027 PSNR 27.26030158996582 [05/05 11:51:51]

[ITER 30000] Saving Gaussians [05/05 11:51:51]


Training complete. [05/05 11:51:54]
root@d618-System-Product-Name: /opt/gaussian-splatting#

```


Obr. 2: Priebeh tréovania modelu pre referenčný dataset pri 30 000 iteráciách.



Obr. 3: Výsledný 3D model z datasetu Lighthouse



Obr. 4: Rekonštrukcia druhého referenčného datasetu




Obr. 5: Priebeh tréovania modelu pri 7 000 iteráciách



Obr. 6: Vizualizácia natrénovaného 3D modelu z datasetu truck

1.2 Snímanie vlastnej scény

V druhej časti bola nasnímaná vlastný dataset na iPhone 13. Ako objekt bola zvolená socha, pretože má členitý tvar a dostatočne výraznú povrchovú štruktúru, čo je vhodné pre hľadanie zhodných bodov. Scéna bola snímaná postupným pohybom kamery okolo objektu tak, aby sa jednotlivé fotografie dostatočne prekrývali. Pri snímaní sme sa snažili zachovať približne rovnaké osvetlenie a nemeniť nastavenia kamery počas celej série fotografií, pričom bol vypnutý auto focus a auto exposure. Pri tréňovaní sme museli znížiť taktiež resolution, aby dokázalo prebehnúť úspešne tréňovanie.



Obr. 7: Riedka rekonštrukcia sochy Jurkoviča

```
root@d618-System-Product-Name: /opt/gaussian-splatting
I0506 08:18:36.087306 4543 undistortion.cc:210] Undistorting image [139/139]
I0506 08:18:36.087313 4543 undistortion.cc:223] Writing reconstruction...
I0506 08:18:36.221689 4543 undistortion.cc:228] Writing configuration...
I0506 08:18:36.222492 4543 undistortion.cc:232] Writing scripts...
I0506 08:18:36.222682 4543 timer.cc:91] Elapsed time: 0.013 [minutes]
Done.
root@d618-System-Product-Name: /opt/gaussian-splatting# python3 train.py -s data/
Jurkovic --data_device cpu --resolution 2 --iterations 7000
Optimizing
Output folder: ./output/8943a522-b [06/05 08:19:51]
Tensorboard not available: not logging progress [06/05 08:19:51]
Reading camera 139/139 [06/05 08:19:52]
Loading Training Cameras [06/05 08:19:52]
Loading Test Cameras [06/05 08:20:33]
Number of points at initialisation : 55190 [06/05 08:20:33]
Training progress: 100%|█| 7000/7000 [17:13<00:00, 6.78it/s, Loss=0.1852334, De

[ITER 7000] Evaluating train: L1 0.0649145357310772 PSNR 19.65750389099121 [06/0
5 08:37:47]

[ITER 7000] Saving Gaussians [06/05 08:37:47]

Training complete. [06/05 08:37:52]
root@d618-System-Product-Name: /opt/gaussian-splatting#
```



Obr. 8: Priebeh tréovania 3D modelu Jurkoviča pri 7 000 iteráciách

```
root@d618-System-Product-Name: /opt/gaussian-splatting
[SIBR] -- INFOS --: Snapping disabled
[SIBR] -- INFOS --: Snapping enabled
[SIBR] -- INFOS --: Snapping disabled
root@d618-System-Product-Name: /opt/gaussian-splatting# python3 train.py -s dat
a/Jurkovic --data_device cpu --resolution 2 --iterations 15000
Optimizing
Output folder: ./output/e08e844e-3 [05/05 18:08:15]
Tensorboard not available: not logging progress [05/05 18:08:15]
Reading camera 139/139 [05/05 18:08:16]
Loading Training Cameras [05/05 18:08:16]
Loading Test Cameras [05/05 18:08:59]
Number of points at initialisation : 55190 [05/05 18:08:59]
Training progress: 47%|█| 7000/15000 [16:41<23:20, 5.71it/s, Loss=0.1930842,
[ITER 7000] Evaluating train: L1 0.06698528230190277 PSNR 19.373026275634768 [
05/05 18:25:41]


[ITER 7000] Saving Gaussians [05/05 18:25:41]
Training progress: 100%|█| 15000/15000 [44:49<00:00, 5.58it/s, Loss=0.1479036

[ITER 15000] Saving Gaussians [05/05 18:53:48]
```

Obr. 9: Priebeh tréovania 3D modelu Jurkoviča pri 15000 iteráciách



Obr. 10: Výsledný 3D model Jurkoviča pri 15000 iteráciách a pri 7000 iteráciách



Obr. 11: Porovnanie odfotenej snímky a 3D modelu sochy

1.3 Vyhodnotenie výsledkov

Pri porovnaní výsledkov bolo viditeľné, že referenčný dataset dosiahol kvalitnejšiu rekonštrukciu ako vlastná scéna. Referenčné dáta boli pravdepodobne nasnímané za lepších podmienok, s väčším počtom záberov, stabilnejším osvetlením a rovnomernejším pokrytím objektu zo všetkých strán.

Pri vlastnej scéne boli výsledky ovplyvnené najmä počtom fotografií, kvalitou prekrytia medzi snímkami, osvetlením a vlastnosťami snímaného objektu. Pri trénovaní vznikol šum v okolí modelu, ktorý mohol byť spôsobný pohybom oblakov alebo stromov v pozadí. Napriek tomu má model veľkú podobnosť s originálnym datasetom. Trénovanie na vlastnom datasete však bolo pre počítač výpočtovo náročné a nepodarilo sa nám spraviť meranie s viac ako 15000 iteráciami na porovnanie.

Záver

V zadaní bol úspešne realizovaný celý postup tvorby 3D scény pomocou metódy 3D Gaussian Splatting. Najskôr bol postup overený na referenčnom datasete a následne bol aplikovaný aj na vlastnoručne nasnímanú scénu. Pomocou COLMAPu boli z fotografií získané pozície kamier a riedky 3D model scény. Po spracovaní dát skriptom `convert.py` bol natrénovaný 3D model.

Referenčný dataset dosiahol lepšiu kvalitu rekonštrukcie, pretože obsahoval vhodnejšie vstupné dáta a pravdepodobne lepšie pokrytie scény. Vlastná scéna mala nižšiu kvalitu najmä z dôvodu náročnejších podmienok snímania, obmedzeného počtu fotografií a možných zmien osvetlenia.